

SAĞLIKTA YAPAY ZEKA YARIŞMASI PROJE DETAY RAPORU

GÖREV: 12 Derivasyonlu EKG Kayıtlarından Üst
Sınıf Kardiyak Durum Sınıflandırma
Yarışma Eğitim Seviyesi: Lise Seviyesi
Proje Adı: EKG-Tarayıcı
Takım Adı: Devre181
Takım ID: #987840
Başvuru ID: #5218603



İÇİNDEKİLER

1. TAKIM ŞEMASI.....	2
2. PROBLEME EN YAKIN ÇÖZÜM SUNAN ULUSLARARASI MAKALELERİN ÖZETİ.....	2
3. VERİ VE YÖNTEM	3
3.1 Kullanılan Veri Seti ve Etiketler	3
3.2 Etiket Güvenilirliği ve Veri Kalitesi Kontrolü	4
3.3 Veri Dengesizliği Nasıl Ele Alındı	5
3.4 Veri Bölme ve Deney Protokolü	5
4. DENEY TASARIMI, SONUÇLAR VE İNCELEME	6
4.1 Sinyal Bölgesi / Zaman Aralığı Seçimi	6
4.2 Performans Metrikleri ve Hata Analizi	7
4.3 “Model Neden Bu Kararı Verdi?” – Açıklanabilirlik Yaklaşımı	7
4.4 Yanlış Sınıflanan Örneklerin İncelenmesi	7
5. YAKLAŞIMIN GEREKÇESİ, TEKNİK EVRİM VE KAYNAK KULLANIMI	8
5.1 Neden Bu Algoritma / Mimari?	8
5.2 Alternatifler Neden Elendi?	9
5.3 Parametre Seçimi ve Deneysel Ayarlar	9
5.4 Öğrenme Süreci ve Teknik Evrim	10
5.5 Hesaplama Kaynakları ve Çalıştırılabilirlik	10
6.REFERANSLAR.....	11

1. TAKIM ŞEMASI

Projemiz; literatür analizi, veri mühendisliği, model optimizasyonu gibi süreçlerin en verimli şekilde yürütülmesi için her üyenin uzmanlığına göre sorumluluk aldığı multidisipliner bir yapıda ilerlemektedir. Ekibimiz, sağıkta yapay zeka çözümlerinin gerektirdiği biyoinformatik, istatistik/ML ve yazılım geliştirme yetkinliklerini eksiksiz karşılayacak şekilde organize olmuştur ve her üye birbiri arasında entegre biçimde çalışmıştır.

Danışman (Akademik Koordinatör): Takımın genel işleyişini denetlemiş, teknik/klinik bilgi akışını sağlayarak model geliştirme, validasyon ve test stratejilerinin bilimsel standartlara uygunluğunu koordine etmiştir.

Takım Kaptanı: Eğitim sonuçlarını analiz ederek sistemdeki mantıksal hataları gidermiş; Macro F1-Score başarısını en üst düzeye çıkarmak için hiperparametre optimizasyonunu ve aşırı öğrenmeyi (overfitting) önleme süreçlerini yönetmiştir.

1. Üye: Uluslararası literatür taramalarını yürüterek projenin teorik altyapısını kurmuş, 12 derivasyonlu EKG sinyallerinin kardiyak ritim/iletim bozukluğu karakteristiklerini çözümlererek klinik alan bilgisi sağlamıştır.

2. Üye: Hedef probleme en uygun derin öğrenme mimarisini belirlemek üzere alternatif modelleri analiz etmiştir. Veri kalitesi kontrol protokollerini oluşturarak eksik, hatalı veya gürültülü verilerin elenmesini ve bilimsel kriterlere uyumu denetlemiştir.

3. Üye: Sinyal verilerinin ön işleme, pencereleme ve veri artırma hatlarına entegrasyonunu sağlamıştır. İlk model eğitimleri için kod derlemelerini gerçekleştirerek performans kayıtlarını yakından takip etmiş ve raporlamıştır.

4. Üye: Projenin yazılım mimarisi ve modüler kod yapısından sorumludur. Geliştirilen modelin dış doğrulama test ortamında kararlı ve donanım kaynaklarını (GPU/bellek) optimize edecek şekilde çalıştırılmasını sağlamıştır.

2. PROBLEME EN YAKIN ÇÖZÜM SUNAN ULUSLARARASI MAKALELERİN ÖZETİ (10 PUAN)

[1] Ribeiro vd. (2020) – 2,3 milyondan fazla EKG kaydında ResNet tabanlı modellerle AF, LBBB ve RBBB tanısı koymuştur (AUC > %95). Büyük ölçekli veri seti en güçlü yönü; sınıf dengesizliği yönetiminin eksikliği ise sınırlılığıdır. Projemizin ham sinyal işleme yaklaşımına temel oluşturmuştur.

[2] Strodthoff vd. (2021) – PTB-XL veri setinde derin öğrenme mimarilerini kıyaslamıştır (Macro F1 ~%70). Hasta bazlı değerlendirme yaklaşımı güçlü yönü, nadir sınıflardaki performans düşüşü sınırlılığıdır. Projemizdeki hasta bazlı veri ayrımı ve Macro F1 odağına referans olmuştur.

[3] Zhu vd. (2020) – Çok etiketli derin öğrenme modeliyle AF, LBBB ve RBBB ritim/iletim bozukluklarını tespit etmiştir (Macro AUC ~%97). Çoklu patolojilerdeki başarısı güçlü yönü, açıklanabilirlik eksikliği ise sınırlılığıdır. Hedef sınıflarımızın belirlenmesinde yol göstermiştir.

[4] Zhou ve Fang (2025) – Lead Attention ve çok ölçekli evrişimle uzamsal ilişkileri modelleyerek Macro F1 değerinde iyileşme sağlamıştır. Derivasyonlar arası etkileşimi modellemesi güçlü yönü, yüksek hesaplama maliyeti sınırlılığıdır. Dikkat mekanizmamızın tasarımına yön vermiştir.

[5] Najia ve Faouzi (2025) – CNN, BiLSTM ve attention mekanizması hibritiyle %99'un üzerinde doğruluk elde etmiştir. Önemli sinyal bölgelerine odaklanması güçlü yönü, karmaşık yapısının eğitim süresini artırması sınırlılığıdır. Dikkat mekanizmalarının mimarimize entegrasyonunu desteklemiştir.

[6] Alghieth (2025) – DeepECG-Net (CNN+Transformer) mimarisiyle %98'in üzerinde doğruluk yakalamıştır. Yerel morfoloji ve uzun dönemli bağımlılıkları öğrenmesi güçlü yönü, yüksek hesaplama gereksinimi sınırlılığıdır. Geliştirdiğimiz hibrit mimariye referans olmuştur.

Literatür; ham EKG sinyallerinde CNN tabanlı hibrit mimarilerin, attention mekanizmalarının ve açıklanabilirlik yaklaşımlarının aritmi sınıflandırmasındaki başarısını göstermektedir. Sınıflandırma ve veri dağılımı ise performansı doğrudan etkileyen sorunlar olarak öne çıkmaktadır. Bu bulgular neticesinde projemizde ResNet-1D+CBAM+Lead-Attention hibrit mimari tercih edilmiş; literatürdeki hasta bazlı veri bölme ve sınıf dengesizliği yönetimi yaklaşımları tasarım sürecimize entegre edilmiştir.

3. VERİ VE YÖNTEM (20 PUAN)

Bu bölümde proje kapsamında kullanılan veri seti, uygulanan veri ön işleme adımları ve geliştirilen derin öğrenme tabanlı sınıflandırma yaklaşımı açıklanmaktadır. Ayrıca modelin eğitim sürecinde izlenen yöntemler ile performans değerlendirme kriterleri özetlenerek önerilen çözümün teknik altyapısı sunulmuştur.

3.1 Kullanılan Veri Seti ve Etiketler (5 puan)

Bu çalışmada amacımıza uygun doğrultuda yarışma kapsamında sağlanan TEKNOFEST veri setine ek olarak PTB-XL, ECG-Arrhythmia ve The Georgia 12-lead ECG Challenge (G12EC) açık veri setlerinden yararlanılmıştır.

PTB-XL veri seti, PhysioNet platformunda yayımlanan ve 12 derivasyonlu EKG kayıtlarını içeren geniş ölçekli bir veri setidir. PTB-XL veri setindeki tanılar SCP-ECG tanı ifadeleri kullanılarak etiketlenmiş olup, bu tanılar SNOMED CT karşılıklarıyla ilişkilendirilmektedir. ECG-Arrhythmia veri seti ise Chapman University, Shaoxing People's Hospital ve Ningbo First Hospital iş birliğiyle oluşturulmuş olup farklı ritim bozukluklarını içeren 12 derivasyonlu EKG kayıtlarından oluşmaktadır. G12EC veri seti ise The PhysioNet/Computing in Cardiology Challenge 2020 kapsamında yayımlanmış olup farklı merkezlerden toplanan ve SNOMED CT tabanlı tanılarla etiketlenmiş 12 derivasyonlu EKG kayıtlarını içermektedir.

Üç açık veri seti de modelin genel EKG örüntülerini öğrenebilmesi amacıyla ön eğitim (pre-training) aşamasında kullanılmıştır. Ardından model, yalnızca proje kapsamındaki

Normal, AFIB, AFL, LBBB ve RBBB sınıfları kullanılarak TEKNOFEST veri seti üzerinde ince ayar (fine-tuning) ile eğitilmiştir. Açık veri setlerinde yer alan tanımlar, proje kapsamındaki beş hedef sınıf ile eşleştirilerek ortak bir etiket yapısı oluşturulmuştur.

Veri setlerinin temel özellikleri aşağıdaki tablolarda özetlenmiştir.

Veri Seti	Kaynak	Toplam Kayıt	Örnekleme Frekansı / Kayıt Uzunluğu	Kullanım Amacı	Dosya Formatları
TEKNOFEST	TEKNOFEST	5000	500Hz / 10sn	Fine-tuning	.mat / .dat ve .hea
PTB-XL	PhysioNet	21.799	500Hz / 10sn	Pre-training	.dat ve .hea
ECG-Arrhythmia	PhysioNet	45.152	500Hz / 10sn	Pre-training	.mat ve .hea
G12EC	PhysioNet Challenge	10.344	500Hz / 5-10sn	Pre-training	.mat ve .hea

	PTB-XL	ECG-Arrhythmia	Georgia (G12EC)	TEKNOFEST	Toplam
NORMAL	9514	8125	1749	1000	20388
AFIB	1514	1780	570	1000	4864
AFL	73	8060	186	1000	9319
RBBB	1659	1745	542	1000	4946
LBBB	613	240	231	1000	2084
Toplam	13373	19950	3278	5000	41601

3.2 Etiket Güvenilirliği ve Veri Kalitesi Kontrolü (5 puan)

Model eğitime geçilmeden önce veri setlerinde aşağıdaki metotlarla güvenlik sağlanmıştır:

Tüm kayıtlar dosya bütünlüğü açısından incelenmiş; okunamayan dosyalar, eksik derivasyon içeren kayıtlar ve 8 saniyelik kayıt süresine ulaşamayan kayıtlar veri setinden çıkarılmıştır. Ayrıca tüm kayıtların örnekleme frekansları doğrulanarak ortak işleme yapısına uygunluğu kontrol edilmiştir.

PTB-XL veri setindeki SCP-ECG tanımları, G12EC veri setindeki SNOMED CT tanımları ve Chapman veri setindeki klinik tanımlar proje kapsamında kullanılan Normal, AFIB, AFL, LBBB ve RBBB etiketleriyle eşleştirilmiştir. 5 hedef sınıf dışındaki kayıtlar yalnızca validasyon aşamasında güven eşiği kalibrasyonu sürecinde değerlendirilmek üzere saklanmıştır. Farklı veri setlerinden gelen kayıtların frekans ve format uyumsuzluklarını gidermek amacıyla tüm sinyaller ortak bir örnekleme frekansına yeniden örneklenmiştir. Ayrıca NaN değer içeren kayıtlar doğrudan elenmiş, kanal standart sapması 10^{-6} mV'un altında olan derivasyonlar ölü kanal olarak değerlendirilmiştir. Ayrıca mutlak genliği 10 mV'u aşan veya örneklerinin %5'inden fazlası ADC'nin minimum ya da maksimum değerinde bulunan (clipping) kayıtlar ile belirgin gürültü içeren sinyaller kalite kontrolünden geçirilerek veri

setinden çıkarılmıştır. Bu kapsamda düşük 0.5-45Hz bandpass filtre ve yüksek frekanslı (50Hz notch filtre) gürültü bileşenleri bastırılarak EKG'nin klinik olarak anlamlı frekans bandı korunmuştur. Tüm EKG kayıtları 250 Hz'e yeniden örneklenmiştir. Veri setleri birleştirilmeden önce yinelenen kayıtlar kontrol edilmiş ve tekrarlar (100 adet) temizlenmiştir.

3.3 Veri Dengesizliği Nasıl Ele Alındı (5 puan)

Kullanılan PTB-XL, Chapman, G12EC ve TEKNOFEST veri setlerinin ortak kullanılması, ciddi sınıf dengesizliği problemi ortaya çıkmaktadır.

“Normal” sınıfı tüm verisetlerinde baskın olup %49.01'lik bir payı vardır. Buna karşılık LBBB başta olmak üzere AFIB ve AFL sınıflarına göre eğitim sırasında büyük bir baskınlık oluşturup modelin çoğunluk sınıfa yönelme riskini artırmaktadır. Modelin eğitimi için verisetlerinden yalnızca 18000 Normal ve 8000 AFL sınıflı veri kullanılmış, kalan üç sınıfı dengelemek için bahsedilen adımlar uygulanmıştır:

İlk olarak sınıf bazlı ağırlıklandırma kullanılarak her sınıfa ters frekansa dayalı log-ölçekli ağırlıklar atanmıştır. Örneğin veri dağılımına göre ağırlığı 4.7 olan LBBB sınıfının agresif katsayısı, bunu 2.9'a düşürmüştür.

Ayrıca sınıf dengesizliğiyle mücadele etmek için, Asymmetric Loss (ASL) fonksiyonu entegre edilmiştir. ASL, doğru tahminlerde ceza üretmeyerek modelin aşırı güvenli (overconfident) olmasını engellerken, özellikle azınlık sınıflardaki yanlış negatiflere çok daha sert cezalar keserek modelin klinik hassasiyetini maksimize etmektedir. Buna ek olarak, kayıp fonksiyonu, sınıfların veri setindeki ters frekanslarına göre hesaplanan Class-Weight parametreleri ile ölçeklendirilmiştir.

Az örnekli LBBB, AFIB ve RBBB sınıflarında ise Gaussian gürültüsü ekleme ve genel morfolojiyi bozmayacak, 0.95- 1.05 oranlarında genlik ölçekleme gibi sinyal tabanlı veri artırma yöntemleri kullanılarak eğitim örnekleri artırılarak nihai veri tablosu çıkartılmıştır:

Veri Dağılımı ve Ağırlık Tablosu	NORMAL	AFIB	AFL	RBBB	LBBB
Dahil edilen veri	18000	4800	8000	4900	2000
Veri artırma sonucu	18000	9600	8000	9800	4000
Sınıfların ağırlık dağılımı	0.45	1.0	1.2	0.85	2.9

3.4 Veri Bölme ve Deney Protokolü (5 puan)

Veri bölme işlemi sınıf dağılımını koruyacak şekilde stratified sampling yaklaşımıyla gerçekleştirilmiştir. Aynı hastaya ait kayıtların farklı kümelerle düşmesini engellemek için hasta bazlı ayırım prensibi uygulanmıştır.

Ön eğitim aşamasında PTB-XL, Chapman ve Georgia verisetleri %80 eğitim, %20 doğrulama olarak ayrılmış; fine-tuning aşamasında ise TEKNOFEST veri seti %70 eğitim, %15 doğrulama ve %15 test kümelerine bölünmüştür. Eğitim aşamasına paralel olarak, validasyon sürecinde ilk üç verisetinden alınan verilerle, hedef sınıfları içermeyen 4000 kayıt (ilk aşamada 3000 fine tuning aşamasında 1000 olmak üzere) kullanılarak UNKNOWN

(Safe Fail) Validasyon uygulanmıştır. Validasyon kümesinde Temperature Scaling ile olasılıklar kalibre edilmiş ve ardından Grid Search yöntemiyle her sınıf için F1-skorunu maksimize eden "Sınıfa Özel Güven Eşikleri" belirlenmiştir.

4. DENEY TASARIMI, SONUÇLAR VE İNCELEME (20 PUAN)

Bu bölümde geliştirilen modelin farklı deney senaryoları altındaki performansı değerlendirilmiş, elde edilen sonuçlar grafik ve tablolarla desteklenerek analiz edilmiştir. Ayrıca modelin güçlü ve zayıf yönleri, karşılaşılan sorunlar ve bu sorunlara yönelik geliştirilen çözümler ele alınmıştır.

4.1 Sinyal Bölgesi / Zaman Aralığı Seçimi (5 puan)

Model girişi olarak tüm EKG kayıtlarından sabit uzunlukta 10 saniyelik sinyal pencereleri kullanılmıştır. Veriler 250Hz örnekleme frekansına yeniden örneklenmiş ve her kayıt için 2500 (250Hz x 10sn) örnek x 12 derivasyon boyutunda giriş oluşturulmuştur. Ön işleme aşamasında taban çizgisi kayması ve yüksek frekanslı gürültü filtrelenmiş, ardından sinyaller normalize edilerek modele aktarılmıştır.

10 saniyelik pencere uzunluğu; AFIB ve AFL gibi ritim bozukluklarının düzensiz RR aralıklarını, LBBB ve RBBB gibi iletim bozukluklarının ise QRS morfolojisini güvenilir şekilde temsil edebilmesi ve klinik standardı nedeniyle tercih edilmiştir. Ayrıca sabit uzunlukta giriş kullanılması, farklı veri setlerinin ortak bir yapıda işlenmesini sağlayarak eğitim sürecini kolaylaştırmış ve hesaplama maliyetini dengede tutmuştur. Kayıtlar zaten sabit uzunlukta (veya 10 saniyenin altında) olduğundan ek pencere kaydırma (overlap) uygulanmamıştır.

4.2 Performans Metrikleri ve Hata Analizi (5 puan)

Modelin doğrulama kümesinde elde ettiği Macro F1 skoru 0.768, genel doğruluğu %85.3 olarak ölçülmüştür. Model performansı macro F1-score temel alınarak değerlendirilmiş; ayrıca precision, recall ve doğruluk metrikleri ile sınıf bazlı başarılar ayrı ayrı raporlanmıştır. Karışıklık matrisi incelendiğinde hataların benzer morfolojik özelliklere sahip LBBB–RBBB ve AFIB–AFL sınıfları arasında gerçekleştiği gözlemlenmiştir.

Gerçek \ Tahmin	Normal	AFIB	AFL	RBBB	LBBB
Normal	458	12	6	14	10
AFIB	18	203	22	4	3
AFL	9	24	162	3	2
RBBB	8	2	3	132	35
LBBB	7	1	2	29	111

Öğrenme eğrileri incelendiğinde eğitim ve doğrulama kayıplarının benzer şekilde yakınsadığı, belirgin bir aşırı öğrenme davranışı oluşmadığı görülmüştür. Az örnekli sınıflarda gözlenen performans kaybı ise sınıf ağırlıklandırması, Asymmetric Loss ve her sınıf için opti-

mize edilen sınıf bazlı karar eşiklerinin önemli ölçüde azaltılmıştır. Nihai tahmin eşik değerini geçen sınıflar arasından en yüksek güven skoruna sahip sınıf olarak belirlenmiştir. Model performansı yalnızca sınıflandırma doğruluğu üzerinden değil, aynı zamanda karar kapsama oranı ve Unknown (reddetme) oranı üzerinden de değerlendirilmiştir. Karar eşiklerini aşmayan kayıtlar “Unknown” olarak işaretlenerek modelin düşük güvenli tahmin üretmesi engellenmiştir. Bu mekanizma, özellikle sınıflar arası benzerliğin yüksek olduğu AFIB–AFL ve LBBB–RBBB durumlarında yanlış pozitif tahminlerin azaltılmasına katkı sağlamıştır.

Sınıf	Precision	Recall	F1
Normal	0.92	0.92	0.92
AFIB	0.84	0.81	0.82
AFL	0.83	0.81	0.82
RBBB	0.72	0.73	0.73
LBBB	0.69	0.74	0.71
Macro Ortalama	0.80	0.80	0.768

4.3 “Model Neden Bu Kararı Verdi?” – Açıklanabilirlik Yaklaşımı (5 puan)

Model kararlarının yorumlanabilirliğini artırmak amacıyla, mimaride yer alan CBAM ve Lead-Attention mekanizmalarından elde edilen dikkat (attention) ağırlıkları analiz edilmiştir. Böylece modelin karar verirken hangi derivasyonlara ve sinyal bölgelerine daha fazla önem verdiği görselleştirilmiş ve şeffaflık artırılmıştır.

Örnek olarak AFIB tanısı verilen bir kayıta modelin dikkat ağırlığının yaklaşık %68'inin II, V1 ve aVF derivasyonlarında yoğunlaştığı, bu bölgelerde düzensiz RR aralıkları ve P dalgasındaki düzensizliklerin karar üzerinde belirleyici olduğu gözlenmiştir. Benzer şekilde LBBB örneklerinde ise dikkat ağırlığının V5, V6 ve I derivasyonlarında yoğunlaştığı ve geniş QRS morfolojisinin modele en yüksek katkıyı sağladığı görülmüştür.

Ayrıca yanlış sınıflandırılan örnekler incelendiğinde, özellikle düşük sinyal kalitesine sahip kayıtlarda dikkat dağılımının daha geniş bir zamana yayıldığı ve model güven skorlarının belirgin şekilde azaldığı gözlemlenmiştir. Bu analizler, modelin karar mekanizmasının anlaşılmasına katkı sağlamış ve sınıf bazlı güven eşiklerinin belirlenmesinde destekleyici olarak kullanılmıştır.

4.4 Yanlış Sınıflanan Örneklerin İncelenmesi (5 puan)

Modelin sınırlarını değerlendirmek amacıyla yanlış sınıflandırılan örnekler vaka bazında incelenmiştir. Çıktılar birlikte değerlendirildiğinde en sık hataların morfolojik olarak benzerlik gösteren LBBB–RBBB ile ritim özellikleri yakın olan AFIB–AFL sınıfları arasında gerçekleştiği gözlenmiştir. Bu hataların temel nedeni genellikle düşük sinyal kalitesi, QRS komplekslerinin belirsizleşmesi ve P dalgası görünürlüğünün azalmasıdır.

Örnek bir vakada gerçek etiketi LBBB olan bir kayıt, QRS genişliğinin yeterince belirgin olmaması nedeniyle RBBB olarak sınıflandırılmıştır. Attention haritaları incelendiğinde modelin ilgili QRS bölgelerine odaklandığı ancak sınıflar arası ayırt edici özelliklerin zayıf olduğu sinyallerde karar güveninin düştüğü görülmüştür. Benzer şekilde AFIB içeren bazı kayıtlarda RR düzensizliği belirgin olmamasına bağlı olarak model AFL sınıfına daha yüksek skor atamıştır.

Ayrıca bazı kayıtlar hiçbir sınıf için belirlenen karar eşiğini aşamamış, bu durum model tarafından düşük güvenli tahmin olarak değerlendirilmiştir. Bu tür örnekler özellikle gürültü oranı yüksek veya morfolojik olarak sınırdaki sinyallerde ortaya çıkmıştır. Bu yapı, yanlış-pozitif tahminleri azaltırken belirsiz vakaların ayrıştırılmasına katkı sağlar.

5. YAKLAŞIMIN GEREKÇESİ, TEKNİK EVRİM VE KAYNAK KULLANIMI (40 PUAN)

Bu bölümde geliştirilen sistemin tasarım süreci boyunca yapılan temel teknik seçimler ve ardındaki gerekçeler ele alınmaktadır. Çözüm, veri setlerinin birleştirilmesi, ön işleme adımları, sınıf dengesizliği yönetimi ve modelleme stratejilerinin evrimi üzerinden şekillendirilmiştir. Özellikle mimari yapısı, CBAM ve lead-attention (transformer) mekanizmaları ile birlikte EKG sinyallerinin zaman ve derivasyon düzeyinde daha anlamlı temsil edilmesi hedeflenmiştir. Ayrıca pre-training ve fine-tuning aşamalarıyla ritim örüntülerinden hedef sınıflara kademeli bir öğrenme süreci kurgulanmıştır.

5.1 Neden Bu Algoritma / Mimari? (8 puan)

12 derivasyonlu EKG sinyallerinden klinik gerçeklik temelli patoloji tespitinin yapılması ve sistem güvenliğini sağlamak üzere tasarlanan hibrit ResNet-1D+ CBAMTransformer mimarisi geliştirilmiştir. Bu mimari tercihinin somut teknik ve kardiyografi temelli gerekçeleri şunlardır:

ResNet-1D: LBBB/RBBB sınıfları QRS kompleksinin genişliği gibi mikro-morfolojik anomaliler barındırırken, AFIB ve AFL uzun dönemli makro-zamansal R-R düzensizlikleri ve P dalgası kayıpları ile bulunur. Her derivasyonu bağımsız olarak işleyerek lokal morfolojik öznitelikleri çıkartmak için 4-blok derin ResNet-1D omurgası tercih edilmiştir. Residual bağlantılar da derin katmanlardaki gradyan sönümlenmesini engeller.

CBAM Entegrasyonu: Klinik ortamdan kaynaklanan gürültülerin kararı bozmasını engellemek amacıyla evrişim katmanlarının ardına Convolutional Block Attention Module (CBAM) eklenmiştir. CBAM'in Kanal Dikkat modülü tanı için kritik derivasyonları öne çıkarıp artefaktlı kanalları baskımlarken, Zaman Dikkat modülü sinyalin patoloji içeren spesifik anlarına (QRS kompleksi vs.) odaklanmayı sağlar.

Transformer Encoder: Global Average Pooling (GAP) ile zaman boyutu sıkıştırılan öznitelikler, uzaysal kalp eksenini korelasyonunu yakalamak üzere Pre-LN Transformer Encoder'a aktarılır. Sinyale eklenen öğrenilebilir CLS token'ı ve Multi-Head Self-Attention mekanizması, 12 derivasyon arasındaki elektriksel yayılım ilişkisini ve global ritmi modeller.

Sigmoid Aktivasyonu: Klinik doğruluktan ödün verilmeyerek bir hastada iki farklı bozukluğun bulunması ihtimalinin önü kapatılamamıştır. Bu yüzden çıkış katmanında Softmax yerine Sigmoid tercih edilerek modelin multi-label (çoklu etiketli) çalışması projeye dahil edilmiştir.

Unknown Karar Mekanizması: Modelimizin yabancı bir EKG görüntüsüyle karşılaşması (ör. MI), bilmediği morfolojiyi mevcut sınıflara benzetip yanlış tahminler üretmesine sebep olur. En doğru klinik çıktıyı vermek için “Safe Fail” yaklaşımı tercih edilip modelin karar uzayındaki 5 sınıfın dışına negative sampling metodu entegre edilmiştir. Bu veriler, modele $[0,0,0,0,0]$ hedef vektörü ile birer negatif çıpa olarak tanıtılır, model aktivasyon değerlerini sıfıra baskılamayı öğrenerek veriyi bilinmeyen bir sinyal olarak değerlendirir. Sistem ham skorları doğrudan bir tanıya dönüştürmek yerine validasyon setinde optimize edilmiş her bir hastalık için F-1 skorunu maksimize edecek şekilde belirlenen Class-Specific Thresholds ve Margin Kontrolü mekanizmalarını devreye sokar. Gelen sinyal modelin “Negatif Çıpa” bölgesinde durur veya belirlenen güven eşiklerinin hiçbirini aşamıyorsa sistem veriyi Unknown statüsüne çeker. Böylece model, yanlış teşhis koymak yerine “sınıflara dahil değil” şeklinde bir tanı koymuş olur.

5.2 Alternatifler Neden Elendi? (8 puan)

Bu çalışma kapsamında değerlendirilen bazı alternatif yaklaşımlar, problem yapısı ve veri özellikleri nedeniyle nihai mimari olarak tercih edilmemiştir.

1.Klasik Makine Öğrenmesi (SVM vb.): Ham EKG sinyalinden manuel özellik çıkarımı gerektirdiğinden, P-QRS-T morfolojilerinin klinik çeşitliliğini temsil etmekte yetersiz kalmıştır. Farklı derivasyonlar arası ilişkileri (elektiriksel eksen) modelleyememesi, performans ve genelleme kapasitesini ciddi oranda sınırlamıştır.

2.Saf Transformer Mimarileri: Uzun menzilli bağımlılıkları modellemede güçlü olsalar da, düşük *inductive bias* (tümevarımsal yanlılık) nedeniyle sınırlı veri setlerinde yakınsama sorunu yaşamış ve aşırı öğrenme (overfitting) riskini artırmıştır.

3.Softmax Tabanlı Mimari: Çıkış katmanında Softmax fonksiyonu kullanan yaklaşımlar, sınıfları birbirini dışlayan (mutually exclusive) bir yapıda kurgular. Oysa klinik pratikte bir hastada hem ritim (AFIB) hem de iletim (RBBB) bozukluğu aynı anda bulunabilir. Softmax, sınıflar arası bu çoklu etiket (multi-label) ilişkisini baskılayıp olasılıkları toplamsal olarak 1’e zorladığı için, klinik doğruluktan ödün verdiği gerekçesiyle elenerek yerine Sigmoid temelli yapı tercih edilmiştir.

5.3 Parametre Seçimi ve Deneysel Ayarlar (8 puan)

Modelin temel hiperparametreleri literatürde yaygın olarak kullanılan başlangıç değerleri esas alınarak belirlenmiş, ardından doğrulama kümesi üzerinde yapılan deneylerle optimizasyona gidilmiştir.

EKG kayıtları 250 Hz’de 10 saniyelik (2500 örnek) sabit uzunlukta işlenmiştir. Eğitimde AdamW (weight decay = 1×10^{-4}) kullanılmış; öğrenme oranı ilk 5 epoch doğrusal warm-

up ile 1×10^{-3} değerine çıkarılıp ardından cosine annealing ile 1×10^{-5} seviyesine düşürülmüştür.

Ön eğitim aşamasında batch boyutu 64 ve 80–100 epoch, ince ayar (fine-tuning) aşamasında ise batch boyutu 32 ve 20–30 epoch tercih edilmiştir.

Modelin genelleme yeteneğini artırmak amacıyla sınıf dengesizliği Asymmetric Loss ($\gamma_{pos}=0$, $\gamma_{neg}=2$) ve doğrulama kümesi üzerinde optimize edilen class weight değerleri ile yönetilmiş; az örnekli sınıflar için gürültü ekleme ve baseline wander tabanlı veri artırma yöntemleri uygulanmıştır.

Sınıflandırma katmanı öncesinde 0.2 dropout, gradient clipping (max norm=1.0) ve doğrulama kümesindeki Macro F1 değerini izleyen 5 epoch sabır değerine sahip early stopping mekanizması kullanılarak aşırı öğrenme önlenmiştir. Eğitim tamamlandıktan sonra temperature scaling ile olasılık skorları kalibre edilmiş, karar eşiği ise doğrulama kümesinde 0.50-0.95 aralığında 0.01 adımlarla yapılan tarama sonucunda en yüksek Macro F1 değerini sağlayacak şekilde belirlenmiştir.

5.4 Öğrenme Süreci ve Teknik Evrim (8 puan)

Model geliştirme süreci, farklı deneylerde karşılaşılan problemlerin analiz edilmesi ve bu problemlere yönelik iyileştirmelerin kademeli olarak uygulanmasıyla ilerlemiştir.

1. Aşama: Mimari ve Veriseti: Yalnızca temel CNN tabanlı yapı kullanıldığında modelin AFIB ve LBBB gibi az örnekli sınıflarda düşük başarı gösterip Normal sınıfına yöneldiği gözlemlenmiş ve Macro-F1 skoru yaklaşık 0.59 olarak tespit edilmiştir. Bu nedenle mimari ResNet-1D omurgası üzerine CBAM ve Transformer tabanlı attention bileşenleri eklenerek yeniden tasarlanmıştır. Ayrıca veri setlerindeki duplicate kayıtların ve ölü kanalların performansı bozduğu görülmüştür. Fingerprinting ile mükerrer kayıtlar temizlenmiş; ölü kanallar, genlik aşımı (10 mV üstü) ve ADC kırılması (clipping) gösteren kayıtlar elenmiştir. Hasta bazlı ayırım (GroupShuffleSplit) ile veri sızıntısı önlenmiştir.

2. Aşama: Sampler Deformasyonu ve Overconfidence: Sistemdeki sınıf dengesizliğini çözmek için kullanılan WeightedRandomSampler'ın verinin doğal olasılık dağılımını (prior) bozduğu ve modelin bilmediği sınıflarda *overconfidence* (aşırı güven) ürettiği tespit edilmiştir. Ayrıca Sampler modelin kalibrasyon yeteneğini yok etmiş ve "dağılım dışı" (OOD) verileri (MI, WPW vb.) 5 hedef sınıfa zorla atmasına neden olmuştur. Ayrıca derivasyonlar arası ilişkilerin zayıf kalması performans kaybına yol açmıştır. Sonuç olarak Sampler sistemden tamamen kaldırılmış, sınıf dengelenmesi ASL (Asymmetric Loss) ve Class-Weight katmanlarına devredilmiştir. Bellek darboğazı HDF5 RAM Caching ile aşılmıştır. Çıktıların güvenilirliği için *Temperature Scaling* ve *Threshold Sweep* ile Safe-Fail Karar Motoru (Unknown mekanizması) kurgulanmıştır. Çıktı olarak, hedef dışı sinyallerin yanlış sınıflandırılması engellenmiş ve nihai Macro-F1 skoru 0.768 seviyesine ulaştırılarak klinik olarak güvenli bir sistem elde edilmiştir.

5.5 Hesaplama Kaynakları ve Çalıştırılabilirlik (8 puan)

Modelin eğitim ve çıkarım süreçleri, Intel Core i7-14700HX işlemci, NVIDIA GeForce RTX 4070 Laptop GPU (GB VRAM) ve 32 GB RAM bulunan bir geliştirme ortamında yürütülmüştür. Yazılım altyapısı olarak Windows 11 işletim sistemi üzerinde Python 3.12 ve PyTorch (CUDA) kullanılmış; veri işleme aşamalarında ise wfdb, NumPy, SciPy, h5py, pandas ve scikit-learn kütüphanelerinden yararlanılmıştır.

Ön eğitim aşamasında yaklaşık 37.000~ EKG kaydı 64 batch boyutuyla ve 30 epochla eğitilmiş ve toplam eğitim süresi 2~ saat sürmüştür. TEKNOFEST veri seti üzerinde gerçekleştirilen ince ayar (fine-tuning) sürecinde ise 32 batch boyutu kullanılmış ve eğitim 20~ dakika içerisinde tamamlanmıştır. Eğitim sırasında HDF5 tabanlı önbellekleme uygulanarak veri okuma darboğazı azaltılmış, GPU bellek kullanımı ise yaklaşık 3-5GB VRAM seviyesinde tutulmuştur. Böylece model, 8GB bellek kapasitesine sahip yaygın GPU'larda ek optimizasyona ihtiyaç duymadan eğitilebilmektedir. HDF5 tabanlı önbellekleme sayesinde veri yükleme süresi önemli ölçüde azaltılmış, bir epoch'un eğitim süresi yaklaşık 12 dakikadan 2 dakikanın altına düşürülmüştür.

Çıkarım süresinin GPU üzerinde yaklaşık 5-10 ms, CPU üzerinde ise 50~ ms düzeyinde olması beklenmektedir. Düşük bellek gereksinimi ve kısa çıkarım süresi sayesinde geliştirilen sistemin yalnızca yüksek performanslı sunucularda değil, standart hastane bilgisayarlarında ve uygun donanıma sahip taşınabilir EKG sistemlerinde de gerçek zamanlı veya gerçek zamanlıya yakın biçimde çalıştırılabileceği öngörülmektedir.

6. REFERANSLAR

- [1] A. H. Ribeiro et al., “Automatic diagnosis of the 12-lead ECG using a deep neural network,” *Nature Communications*, vol. 11, no. 1, Art. no. 1760, Apr. 2020, doi: 10.1038/s41467-020-15432-4.
- [2] N. Strodthoff, P. Wagner, T. Schaeffter, and W. Samek, “Deep Learning for ECG Analysis: Benchmarks and Insights from PTB-XL,” *IEEE Journal of Biomedical and Health Informatics*, vol. 25, no. 5, pp. 1519–1528, May 2021, doi: 10.1109/JBHI.2020.3022989.
- [3] H. Zhu et al., “Automatic multilabel electrocardiogram diagnosis of heart rhythm or conduction abnormalities with deep learning: A cohort study,” *The Lancet Digital Health*, vol. 2, no. 7, pp. e348–e357, Jul. 2020, doi: 10.1016/S2589-7500(20)30107-2.
- [4] F. Zhou and D. Fang, “Classification of multi-lead ECG based on multiple scales and hierarchical feature convolutional neural networks,” *Scientific Reports*, vol. 15, Art. no. 16418, 2025, doi: 10.1038/s41598-025-94127-6.
- [5] M. Najia and B. Faouzi, “An Enhanced Hybrid Model Combining CNN, BiLSTM, and Attention Mechanism for ECG Segment Classification,” *Biomedical Engineering and Computational Biology*, vol. 16, pp. 1–14, 2025, doi: 10.1177/11795972251341051.
- [6] M. Alghieth, “DeepECG-Net: A Hybrid Transformer-Based Deep Learning Model for Real-Time ECG Anomaly Detection,” *Scientific Reports*, vol. 15, no. 1, Art. no. 20714, Jul. 2025, doi: 10.1038/s41598-025-07781-1.

